

# 日本語小説の BGM 生成のための生成 AI のプロンプトエンジニアリング

メディアインテリジェンス研究室

60266261

二神 暁翔

**概要：**本研究では、生成 AI を用いて、日本語小説の内容に沿った BGM を自動生成する手法を検討した。楽曲の生成には、既存の生成 AI を用いる。本手法では、生成 AI に与えるプロンプトの構成方法を提案する。提案法では、まず、ベクトル分散表現 (Doc2Vec) に変換したテキストのコサイン類似度に基づき、作品をシーンごとに分割する。次に、分割された各シーンにおいて、(1)OpenAI API を用いた英文要約 (2)BERT による 8 感情推定 (3) 推定感情から導出した楽曲構造の 3 要素からプロンプトを構成する。最後に、構成したプロンプトを入力とし、生成 AI (MusicGen) で楽曲を生成した。評価実験では、協力者に、テキスト音声合成による読み上げ音声を与与した BGM を聴取してもらい、小説の原文を生成 AI のプロンプトとした場合と比較した。提案法が選択された割合は作品別に、さるかに合戦：81.3%、他人の夏：34.4%、ごん狐：51.3%であった。特にストーリーが単純で明確な作品においては、提案法を用いた BGM 生成の適合性が確認できた。

**キーワード：**楽曲生成, 自然言語処理, 感情推定, 楽曲構造, 場面分割, text-to-music

## 1 はじめに

テキストプロンプトに基づいて楽曲を生成する、楽曲生成 AI が利用できるようになった。しかし、文学作品から抽出した文章をそのまま楽曲生成 AI のプロンプトとして使用すると、登場人物の感情や文章の印象に適した楽曲構造を反映することができず、適切な BGM を生成することが困難であった。

そこで、本研究では、文章から感情や楽曲構造を推測し、プロンプトの構成要素として明示的に組み込むことを提案する。これにより、各場面の世界観や情景、雰囲気な音楽を得ることができ、小説の内容に整合した BGM を付与できると考える。

### 1.1 システム構成

提案手法の概要を図 1 に示す。提案手法は 3 つの要素から構成される。

1. 入力された日本語小説のテキストを場面分割
2. 場面分割後の文章からプロンプト作成
3. 作成したプロンプトから BGM 生成

## 2 入力文章の場面分割手法

このセクションでは、入力された日本語小説の文章に対して場面分割を行う。楽曲生成 AI が生成する BGM では、変化が伴った複数の曲調を表現することが現時点では難しい。そのため、分割された場面ごとに楽曲を生成し、小説内の文章と楽曲の整合性を高める必要があった。

このプロセスは、5 つのステップから構成される。

1. 入力された各文を分散表現に変換
2. 隣り合う文ベクトルとの平均ベクトルを算出
3. 隣り合う平均ベクトル間のコサイン類似度を算出
4. 算出したコサイン類似度を条件比較
5. 比較結果をもとに、場面の切り替わり箇所を推定



図 1: 提案手法の構成



図 2: 楽曲プロンプト作成の流れ

## 3 楽曲生成 AI のプロンプト作成

このセクションでは、生成 AI に与える楽曲プロンプトを分割した場面ごとに構成する。抽出した要素をもとに、楽曲プロンプトを構成する処理を図 2 に示す。文章から「要約」「推定感情」「楽曲構造」の要素を抽出する。次からは、各要素の決定方法を説明する。

### 3.1 文章要約

文章要約は、場面内の主要な内容を抽出し、適切に楽曲中に含むためのものである。OpenAI API を用いて、場面分割後の日本語小説の文章と 3 文程度の英文要約を作成するように指示したプロンプトを入力とし、出力として英文の要約を得ることができた。

### 3.2 推定感情

推定感情は、文書から受ける感情的な印象の定量化を試みたものである。日本語の感情分析コーパスである WRIME を用いて、日本語 BERT 訓練済みモデルの追加学習を行い、感情分析に使用した。場面内のすべての文に対して、追加学習済み BERT モデルを用いて、場面中の各文に対して感情推定を行った。そして、すべての文の感情を集計し、場面中の各感情（喜び、悲しみ、期待、驚き、怒り、恐れ、嫌悪、信頼）の出

現確率を算出した。

### 3.3 楽曲構造

楽曲構造は、文章や感情の要素のみでは推測が難しい要素を補うために、推定した感情に応じて決定される。Hevner[1][2]では、印象語群と楽曲構造の対応が定義されており、本研究では、感情に対応する楽曲構造の定義に同研究の成果を用いた。手法としては、もっとも出現確率が高い感情をその場面のBGMの代表感情とする。その後、先行研究[1][2]で紐づけられたルールに沿って、代表感情に対応した楽曲構造を決定した。例えば、喜びを代表感情とした場合、楽曲構造は「major key, fast tempo, high pitch, fluid rhythm, simple harmony」となる。

## 4 生成 AI モデルを用いた BGM 生成

提案法で作成した楽曲プロンプトを入力として、楽曲生成 AI (MusicGen) を用いて BGM を出力するプロトタイプシステムを実装した。生成した BGM の再生時間は、オリジナルの小説の文書をテキスト音声合成ソフトウェアで読み上げた場合と同一時間とした。

## 5 生成された BGM の評価

本研究では、提案法で出力した BGM の適正を確認するために主観評価実験を実施した。

### 5.1 実験手順

主観評価による実験手順を図 3 に示す。聴取の対象は、(1) 提案法による楽曲プロンプトと、(2) 分割した小説のテキストそのものの 2 条件のプロンプトを入力として楽曲生成 AI で出力した BGM である。

それぞれには、オーディオブック風の音源となるように、テキスト音声合成ソフトウェアで作成した読み上げ音声を付与した。今回の実験では、3 作品分の 12 セット（各作品 3～5 場面）計 24 種類の音源を準備した。

実験では、作成した音源を実験協力者に聴取してもらった。実験協力者は 19 歳～25 歳の学生 16 名である。1 セットごとに、(1) 提案法と (2) 文章そのままによる音源を聴取し、より読み上げ音声の作品により適合していると感じた方を選択する二者択一で評価した。順序効果を避けるため、各セットの提示順序はランダムである。

### 5.2 実験結果

主観評価の結果を表 1 に示す。2 条件のうち、(1) 提案法による BGM が選択された割合は 53.1% であった。作品別では、さるかに合戦：81.3%、他人の夏：34.4%、ごん狐：51.3% となった。ストーリー展開や表現に複雑なものが含まれる作品では、(1) 提案法による楽曲プロ




図 3: 主観評価の実験手順

表 1: 主観評価結果

| 「作品名」 著者         | 場面   | (1) 提案法の選択割合 |
|------------------|------|--------------|
| 「さるかに合戦」<br>楠山正雄 | 場面 1 | 93.8%        |
|                  | 場面 2 | 81.3%        |
|                  | 場面 3 | 68.8%        |
| 「他人の夏」<br>山川方夫   | 場面 1 | 75.0%        |
|                  | 場面 2 | 25.0%        |
|                  | 場面 3 | 18.8%        |
|                  | 場面 4 | 18.8%        |
| 「ごん狐」<br>新美南吉    | 場面 1 | 50.0%        |
|                  | 場面 2 | 37.5%        |
|                  | 場面 3 | 75.0%        |
|                  | 場面 4 | 37.5%        |
|                  | 場面 5 | 56.3%        |

ンプトでは BGM を生成するための情報が不十分であると考えられる。また、プロンプトに含まれる英文要約の内容が場面の文章と一致しない場合、(1) 提案法の選択が低下する傾向にあった。

## 6 おわりに

本研究では、生成 AI による日本語小説の BGM 生成のためのプロンプト作成手法を提案した。また、既存の生成 AI を用いて提案法のプロトタイプを実装した。主観評価の結果、作品のストーリー展開や表現の複雑さによって、提案手法の適合性が異なることが明らかになった。今後の課題として、楽曲プロンプト内の要約精度の向上や楽曲プロンプトを構成する要素の見直しが挙げられる。また、生成音からのノイズの除去や客観的な評価尺度の見直しも今後の課題と考える。

## 参考文献

- [1] Kate Hevner. Experimental studies of the elements of expression in music. *The American Journal of Psychology*, Vol. 48, No. 2, pp. 246–268, 1936.
- [2] Kate Hevner. The affective value of pitch and tempo in music. *The American Journal of Psychology*, Vol. 49, No. 4, pp. 621–630, 1937.